Génération de champs de précipitations extrêmes en France

Comparaison entre VAE, GAN et WGAN-GP

Auteurs : Nom Prénom 1
Nom Prénom 2
Nom Prénom 3

Encadrant : Nom Prénom

ENSAE Paris

27 avril 2026

Introduction & Enjeux

Le problème :

- Évaluer les risques climatiques (inondations, infrastructures) nécessite d'explorer la **queue de distribution** des événements rares.
- Les Modèles de Circulation Générale (GCM) sont physiquement robustes mais **trop lents et coûteux** pour générer de très grands ensembles.

Notre objectif :

- Évaluer les **Modèles Génératifs Profonds (DGM)** comme émulateurs climatiques stochastiques rapides.
- Cible : Générer l'indice **Rx5day** (précipitation maximale sur 5 jours consécutifs).
- Défi : Reproduire la structure spatiale, l'asymétrie statistique et les contrastes régionaux.

Données et Prétraitement

Source des données :

- Copernicus CDS : projections globales **CMIP6** [1, 2].
- Fenêtre spatiale : France métropolitaine (8×10 pixels).

Le défi du Min-Max Scaling :

- Normalisation vers $[0, 1]$ obligatoire pour les réseaux de neurones (activations sigmoïdes).
- **Problème :** Les extrêmes suivent une loi à queue lourde. Le scaling écrase la vaste majorité des valeurs près de 0.
- **Conséquence :** L'apprentissage de la différence entre pluie modérée et tempête extrême devient numériquement très difficile.

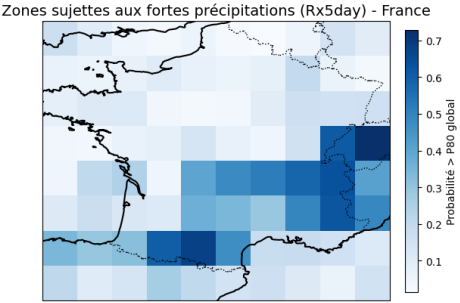

Probabilité empirique de fortes précipitations (P80)

Analyse Exploratoire : Saisonnalité et Asymétrie

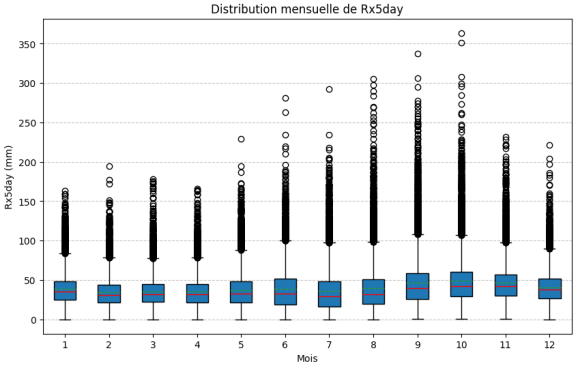

Observations clés :

- **Forte saisonnalité** : Les mois d'automne et d'hiver concentrent les événements les plus intenses.
- **Asymétrie marquée** : Présence de queues droites très longues (événements extrêmes rares).
- Les modèles (VAE/GAN) sont entraînés *sans* conditionnement temporel : ils doivent encoder cette diversité saisonnière de manière non supervisée dans leur espace latent.

Analyse Exploratoire : Structure Spatiale

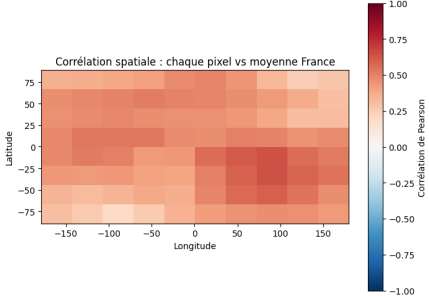

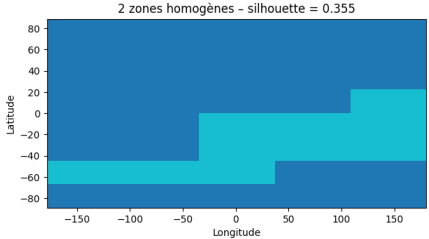

Corrélation Spatiale (Haut) :

- Les pixels voisins réagissent de manière cohérente.
- Justifie l'utilisation d'architectures **CNN** (Réseaux Convolutifs) pour capter les gradients locaux.

Segmentation K-means (Bas) :

- Séparation en 2 zones climatiques nettes.
- **Zone 0** : Influence atlantique (fréquent, modéré).
- **Zone 1** : Influence méditerranéenne/reliefs (sporadique, extrême, ex : épisodes cévenols).

Analyse Exploratoire : Distribution par Zone

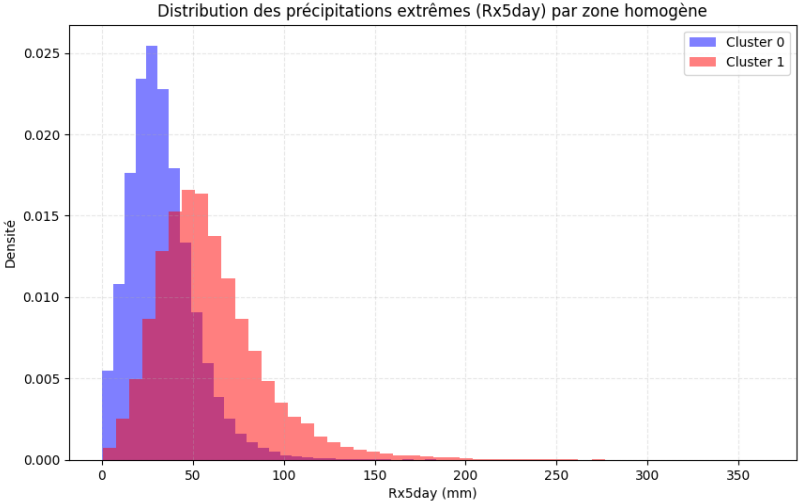

Densité des précipitations extrêmes (Rx5day) par zone climatique.

Autoencodeur Variationnel (VAE) [3]

Architecture :

- Encodeur CNN $\rightarrow$ Espace latent ($dim = 8$) $\rightarrow$ Décodeur CNN.
- Approche probabiliste : le modèle apprend une distribution continue.

Fonction de Perte (ELBO) :

$$\mathcal{L} = \underbrace{\lambda_{\mathrm{rec}} \mathcal{L}_{\mathrm{BCE}}}_{\text{Reconstruction}} + \underbrace{\lambda_{\mathrm{KL}} D_{\mathrm{KL}}(q(z|x) \| p(z))}_{\text{Régularisation}}$$

- Poids λ_{KL} optimal très faible (0.005) pour éviter le *posterior collapse* et forcer la reconstruction détaillée.

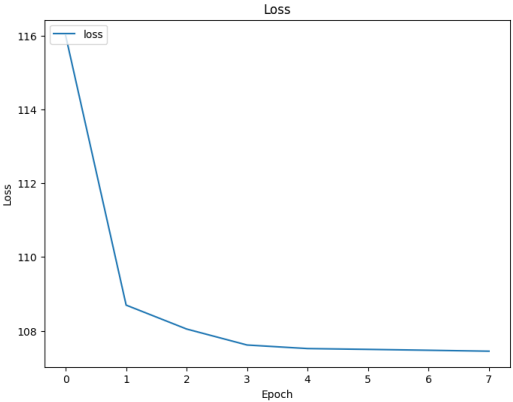

Convergence stable du VAE

Le défi du VAE : L'importance cruciale du Batch Size

Découverte expérimentale majeure :

- Le passage d'un `batch_size` de 16 à 32 provoque un **doublement de la perte finale** (de ≈ 421 à ≈ 850).

Explication physique et algorithmique :

- Les extrêmes climatiques sont, par définition, **rares** et très localisés.
- Avec un **grand batch (32)**, les gradients des rares pixels de fortes tempêtes sont "noyés" et annulés par l'immense majorité des pixels "secs" ou modérés. Le modèle converge vers une prédiction lissée (peu de pluie partout).
- Un **petit batch (16)** maintient la stochasticité (bruit) de la descente de gradient, préservant ainsi le signal des anomalies pluviométriques.

Résultats VAE : Génération et Espace Latent

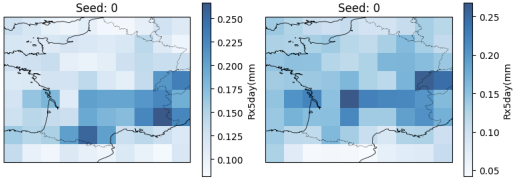

Cartes synthétiques (VAE)

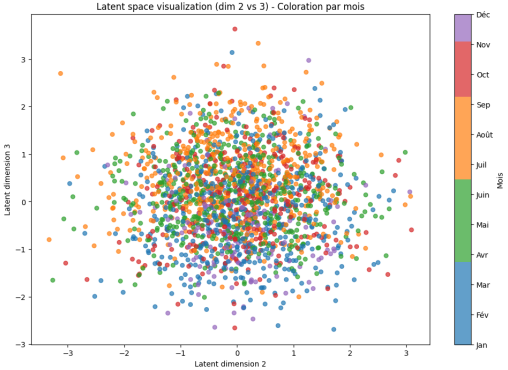

Espace latent projeté par saison

- **Génération** : Cartes cohérentes géographiquement mais intrinsèquement **floutées/lissées**.
- **Latent** : Chevauchement des saisons normal car des tempêtes d'été et d'automne peuvent partager la

Modèles Adversariaux : GAN [4] & WGAN-GP [5]

Objectif : Surmonter le flou du VAE pour générer des contrastes violents (tempêtes).

GAN classique :

- Jeu minimax entre Générateur et Discriminateur probabiliste.
- *Problème* : Convergence très instable, effondrement de mode fréquent.

WGAN-GP :

- Utilise la **distance de Wasserstein** (Earth Mover's Distance).
- Le Discriminateur devient un "Critique" continu.
- Régularisation par pénalité de gradient (GP) pour garantir la stabilité.

Le piège de la sparsité

La précipitation est dominée par des zéros. Le Discriminateur d'un GAN classique repère instantanément les erreurs de sparsité (ex : pluie diffuse là où il ne devrait rien y avoir), rejetant tout en bloc et **tuant le gradient** du Générateur.

Entraînement des GANs : Dynamique et Pertes

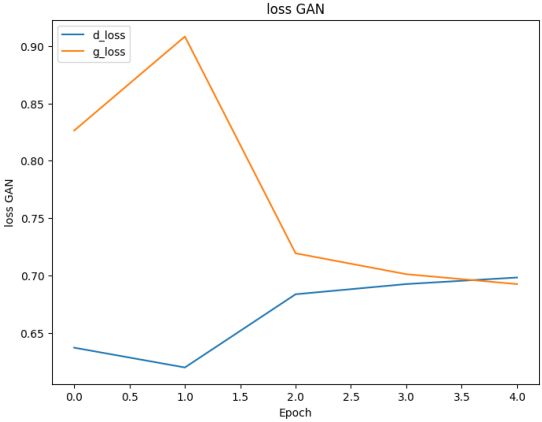

Instabilité du GAN classique (oscillations)

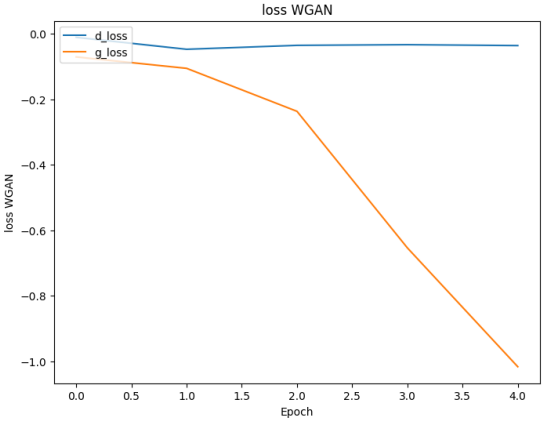

Dynamique plus lisse du WGAN-GP

- La perte de Wasserstein (WGAN-GP) reflète mieux la convergence réelle du modèle et évite le phénomène de mode collapse.

Résultats : GAN vs WGAN-GP

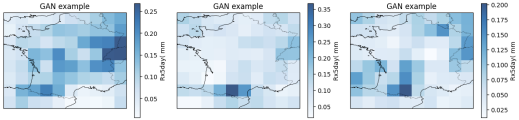

Générations GAN classique

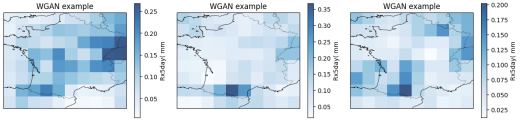

Générations WGAN-GP

- Les modèles adversariaux produisent des **contrastes beaucoup plus abrupts** que le VAE (idéal pour simuler des cellules orageuses locales).
- WGAN-GP offre une diversité supérieure au GAN classique, mais souffre encore d'artefacts géométriques en damier (*checkerboard artefacts*).

Bilan Comparatif des Architectures

Critère	VAE	GAN classique	WGAN-GP
Stabilité d'entraînement	Excellente	Médiocre	Moyenne
Rendu des contrastes extrêmes	Faible (Flou)	Fort	Fort
Interprétabilité (Latent)	Oui (Continu)	Non	Non
Sensibilité à la sparsité	Moyenne	Très élevée	Gérée
Présence d'artefacts	Non	Oui	Oui (Damier)

Conclusion intermédiaire : Aucun modèle n'est parfait isolément. Le VAE est le plus robuste pour explorer le climat, mais le GAN est le seul capable d'émuler la brutalité visuelle d'une tempête.

Conclusion et Perspectives

Synthèse des travaux :

- L'émulation d'extrêmes climatiques (Rx5day) par Deep Learning est possible mais entravée par la distribution asymétrique (queue lourde) des précipitations.
- Le réglage minutieux des hyperparamètres (notamment un petit *batch size* pour le VAE) est une condition *sine qua non* pour ne pas lisser les extrêmes.

Perspectives d'amélioration :

1. **Modèles Hybrides :** Développer un modèle **VAE-GAN** pour allier la stabilité encodée du VAE et la netteté du Critique WGAN.
2. **Génération Conditionnelle :** Injecter des variables forçantes (saison, température, altitude) pour diriger la génération (cGAN).
3. **Métriques Quantitatives :** Dépasser l'évaluation visuelle via la Distance de Wasserstein empirique et la *Fréchet Inception Distance* (FID) climatique.

Références

[1] [1] Copernicus CDS. *Climate extreme indices from CMIP6 projections*. (2025).

[2] [2] Eyring, V. et al. *Overview of the CMIP6 experimental design*. GMD, (2016).

[3] [3] Kingma, D. P., & Welling, M. *Auto-Encoding Variational Bayes*. ICLR, (2014).

[4] [4] Goodfellow, I. et al. *Generative Adversarial Nets*. NeurIPS, (2014).

[5] [5] Gulrajani, I. et al. *Improved Training of Wasserstein GANs*. NeurIPS, (2017).
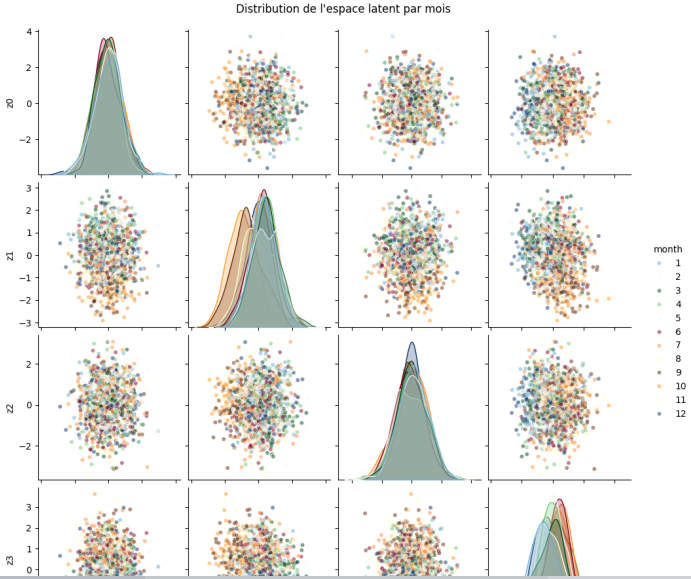
Annexe : Espace Latent VAE (Détails)